Aprendizaje de Máquina I

Trabajo Práctico Grupal

Ribet, Juan Ignacio
Sarmiento, Fabián
Cáceres, Martín Nahuel
Raczkowski, Karen Elizabeth

El trabajo se basa en el analisis de datos realizado rn la materia AdD:
https://github.com/BenjaSar/AdD.git

1. DATASET
2. EVALUACIÓN DE LOS MODELOS
3. SPLIT DATASET
4. MODELOS
5. COMPARACIÓN DE LOS MODELOS
6. AUTO ML
7. CONCLUSIONES

1. DATASET
2. EVALUACIÓN DE LOS MODELOS
3. SPLIT DATASET
4. MODELOS
5. COMPARACIÓN DE LOS MODELOS
6. AUTO ML
7. CONCLUSIONES

1.0. LEGO DATABASE

https://www.kaggle.com/datasets/rtatman/lego-database?resource=download

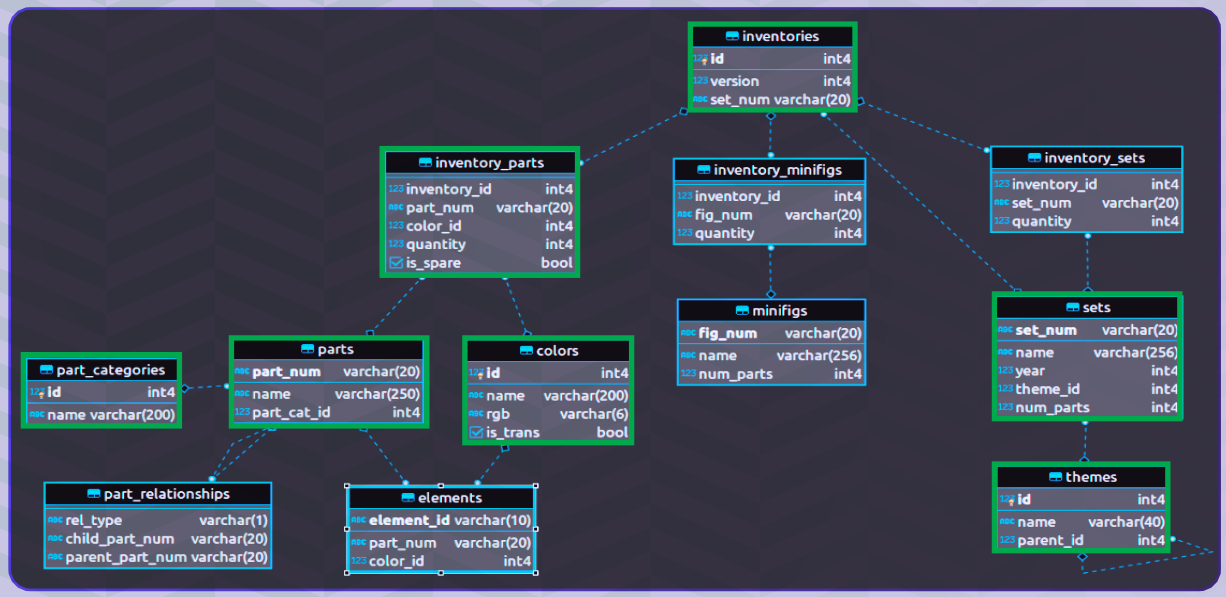

Después de combinar los datasets mencionados, se analizaron las temáticas más frecuentes en los sets de Lego para trabajar sólo con ellas y reducir la cantidad de categorías. Además, se procesaron los datos para obtener la proporción de piezas de cada material, de piezas de cada categoría y de piezas de cada uno de los 10 colores más frecuentes presentes en cada set de Lego.

DATASET

*Se seleccionaron **12 features** basandonos en top 20 por MI y luego eliminando features correlacionadas entre si (Spearman)*

- 'Plates Special'
- 'Bricks'
- 'Duplo, Quatro and Primo'
- 'Minifig Accessories'
- 'gris'
- 'Bricks Sloped'
- 'negro'
- 'Transportation - Land'
- 'Technic Pins'
- 'rojo'
- 'amarillo'
- 'Bars, Ladders and Fences'

1.1. PREGUNTA A RESPONDER

- **¿Podría predecir a qué temática pertenece un set basado en el contenido de este?**

Se trabajará en un problema de clasificación multiclase.
Para responder la pregunta planteada se utilizarán ***los siguientes datasets*** *los cuales darán la información necesaria para trabajar:*

- **themes**
- **sets**
- **inventories**
- **inventory_parts**
- **colors**
- **parts**
- **part_categories**

1.2. BALANCE DE CLASES

Se verifica la participación de cada clase en el dataset.

Duplo	*Star Wars*	*Technic*	*City*	*Town*	*Educational and dacta*	*Friends*	*Ninjago*	*Creator*	*Universal Building Set*
18,32%	**12,36%**	**11,47%**	**10,98%**	**9,46%**	**8,51%**	**7,87%**	**7,61%**	**7,32%**	**6,11%**

1. DATASET
2. EVALUACIÓN DE LOS MODELOS
3. SPLIT DATASET
4. MODELOS
5. COMPARACIÓN DE LOS MODELOS
6. AUTO ML
7. CONCLUSIONES

EVALUACIÓN DE LOS MODELOS

*Para evaluar la performance de los diferentes modelos con los que se trabajará, se crea una función llamada **"evaluar"**. El propósito de la misma está destinado a calcular y mostrar las diferentes métricas de evalucación, así como las matrices de confusión para el modelo de clasificación en los datos de entrenamiento y prueba.*

Las métricas de evaluación con las que se trabajará son:

a • **Accuracy**
b • **Precision**
c • **Recall**
d • **F1**
e • **Matriz de confusión | Train Data**
f • **Matriz de confusión | Test Data**

1. DATASET
2. EVALUACIÓN DE LOS MODELOS
3. SPLIT DATASET
4. MODELOS
5. COMPARACIÓN DE LOS MODELOS
6. AUTO ML
7. CONCLUSIONES

SPLIT DATASET

*Se separa el dataset en **entrenamiento** y **prueba**.*

70%

TRAINING

30%

TESTING

1. DATASET
2. EVALUACIÓN DE LOS MODELOS
3. SPLIT DATASET
4. MODELOS
5. COMPARACIÓN DE LOS MODELOS
6. AUTO ML
7. CONCLUSIONES

MODELOS SELECCIONADOS

4.1. Logistic Regression CV (Balanced - ROS - SMOTE)

4.2. XGB Classifier

4.3. Cat Boost Classifier

4.4. Random Forest Classifier

4.5. Bagging - Tree Classifier

4.6. SVM

4.7. Decision Tree Classifier

Se seleccionaron diferentes modelos en los cuales se evaluará los mismos parámetros en cada caso:

- a • **Accuracy**
- b • **Precision**
- c • **Recall**
- d • **F1**
- e • **Matriz de confusión | Train Data**
- f • **Matriz de confusión | Test Data**

4.1.1. LOGISTIC REGRESSION CV BALANCED

*Para cada modelo se implementaron diferentes métodos de balanceo. Aquí se presentan los resultados del modelo de **LG** utilizando la técnica de **validación cruzada** (cross-validation) y con la opción de **balanceo de clases**.*

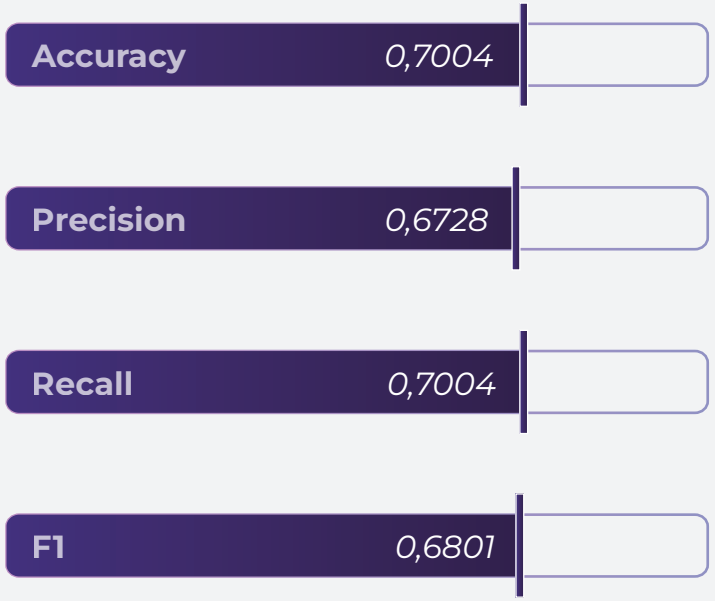

	precision	recall	f1-score	support
City	0.82	0.66	0.73	238
Creator	0.53	0.58	0.56	173
Duplo	0.84	0.96	0.90	392
Educational and Dacta	0.12	0.04	0.06	160
Friends	0.66	0.76	0.70	156
Ninjago	0.61	0.57	0.59	147
Star Wars	0.68	0.56	0.61	230
Technic	0.70	0.90	0.79	222
Town	0.79	0.79	0.79	185
Universal Building Set	0.61	0.83	0.71	117
accuracy			0.70	2020
macro avg	0.64	0.67	0.64	2020
weighted avg	0.67	0.70	0.68	2020

MATRIZ DE CONFUSIÓN | TRAIN DATA

MATRIZ DE CONFUSIÓN | TEST DATA

4.1.2. LOGISTIC REGRESSION CV WITH ROS

*Aquí se utiliza otro se implementa el método de **sobremuestreo aleatorio** para abordar el desequilibrio de clases en los datos de entrenamiento y se aplica el sobremuestreo solo a la clase minoritaria.*

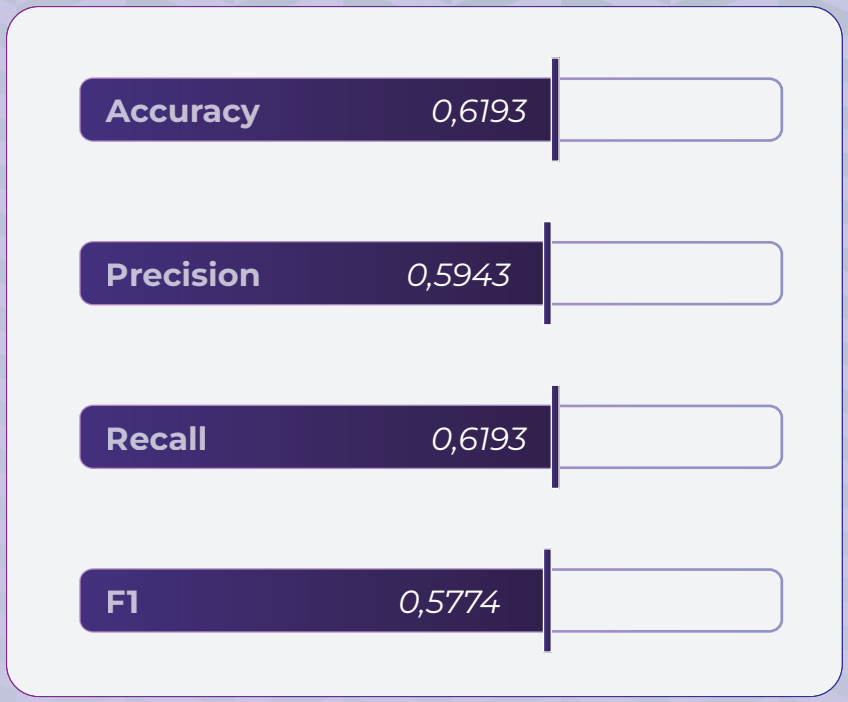

	precision	recall	f1-score	support
City	0.71	0.58	0.64	238
Creator	0.59	0.11	0.19	173
Duplo	0.84	0.97	0.90	392
Educational and Dacta	0.00	0.00	0.00	160
Friends	0.45	0.76	0.57	156
Ninjago	0.64	0.31	0.42	147
Star Wars	0.42	0.68	0.52	230
Technic	0.70	0.69	0.70	222
Town	0.66	0.74	0.70	185
Universal Building Set	0.50	0.85	0.63	117
accuracy			0.62	2020
macro avg	0.55	0.57	0.53	2020
weighted avg	0.59	0.62	0.58	2020

MATRIZ DE CONFUSIÓN | TRAIN DATA

MATRIZ DE CONFUSIÓN | TEST DATA

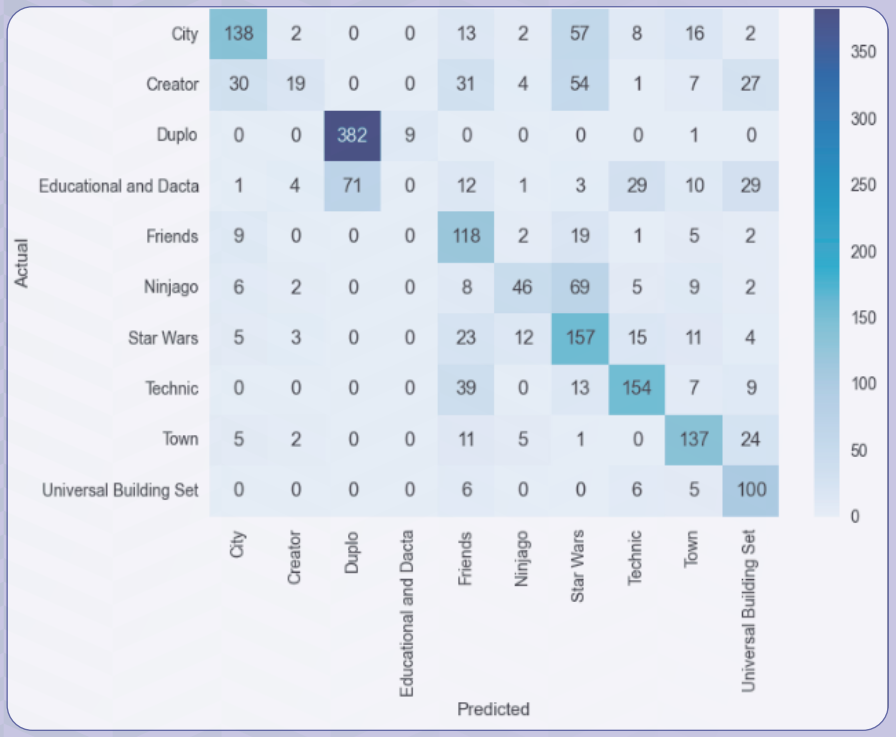

4.1.3. LOGISTIC REGRESSION CV WITH SMOTE

*Aquí se utiliza **LR** con la técnica de Sobremuestreo **SMOTE** (Synthetic Minority Over-sampling Technique) para abordar el desequilibrio de clases.*

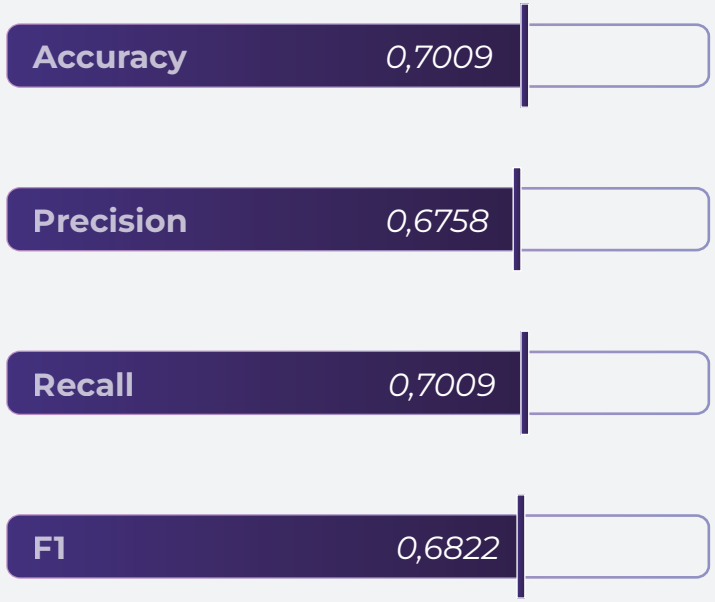

	precision	recall	f1-score	support
City	0.82	0.66	0.73	238
Creator	0.52	0.58	0.55	173
Duplo	0.84	0.95	0.89	392
Educational and Dacta	0.15	0.06	0.08	160
Friends	0.68	0.73	0.71	156
Ninjago	0.60	0.60	0.60	147
Star Wars	0.68	0.57	0.62	230
Technic	0.70	0.89	0.78	222
Town	0.80	0.80	0.80	185
Universal Building Set	0.62	0.83	0.71	117
accuracy			0.70	2020
macro avg	0.64	0.67	0.65	2020
weighted avg	0.68	0.70	0.68	2020

MATRIZ DE CONFUSIÓN | TRAIN DATA

MATRIZ DE CONFUSIÓN | TEST DATA

4.2. XGB CLASSIFIER

Accuracy	0,7643
Precision	0,7481
Recall	0,7643
F1	0,7492

	precision	recall	f1-score	support
City	0.76	0.75	0.76	238
Creator	0.71	0.62	0.66	173
Duplo	0.86	0.96	0.91	392
Educational and Dacta	0.47	0.20	0.28	160
Friends	0.74	0.72	0.73	156
Ninjago	0.70	0.66	0.68	147
Star Wars	0.70	0.74	0.72	230
Technic	0.76	0.96	0.85	222
Town	0.85	0.88	0.86	185
Universal Building Set	0.76	0.82	0.79	117
accuracy			0.76	2020
macro avg	0.73	0.73	0.72	2020
weighted avg	0.75	0.76	0.75	2020

MATRIZ DE CONFUSIÓN | TRAIN DATA

MATRIZ DE CONFUSIÓN | TEST DATA

4.3. CATBOOST CLASSIFIER

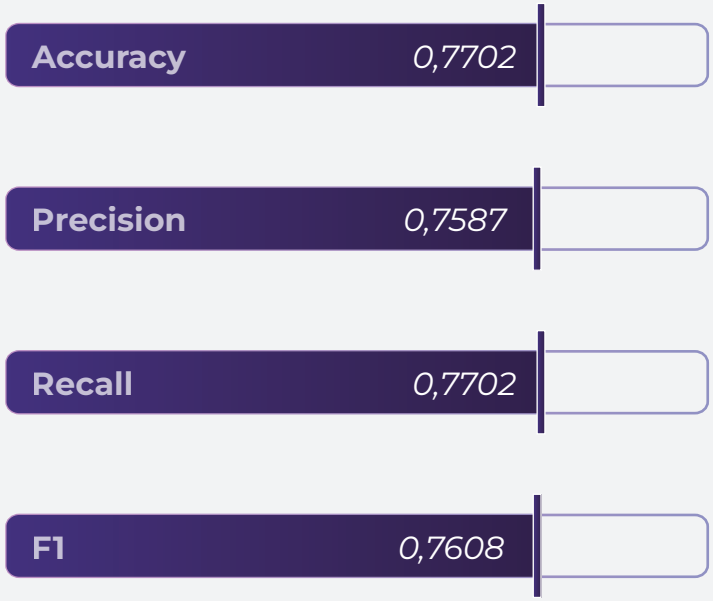

	precision	recall	f1-score	support
City	0.82	0.76	0.79	238
Creator	0.71	0.66	0.68	173
Duplo	0.87	0.91	0.89	392
Educational and Dacta	0.45	0.26	0.33	160
Friends	0.75	0.80	0.78	156
Ninjago	0.69	0.71	0.70	147
Star Wars	0.74	0.71	0.73	230
Technic	0.77	0.95	0.85	222
Town	0.85	0.88	0.86	185
Universal Building Set	0.73	0.82	0.77	117
accuracy			0.77	2020
macro avg	0.74	0.75	0.74	2020
weighted avg	0.76	0.77	0.76	2020

MATRIZ DE CONFUSIÓN | TRAIN DATA

MATRIZ DE CONFUSIÓN | TEST DATA

4.4. RANDOM FOREST CLASSIFIER

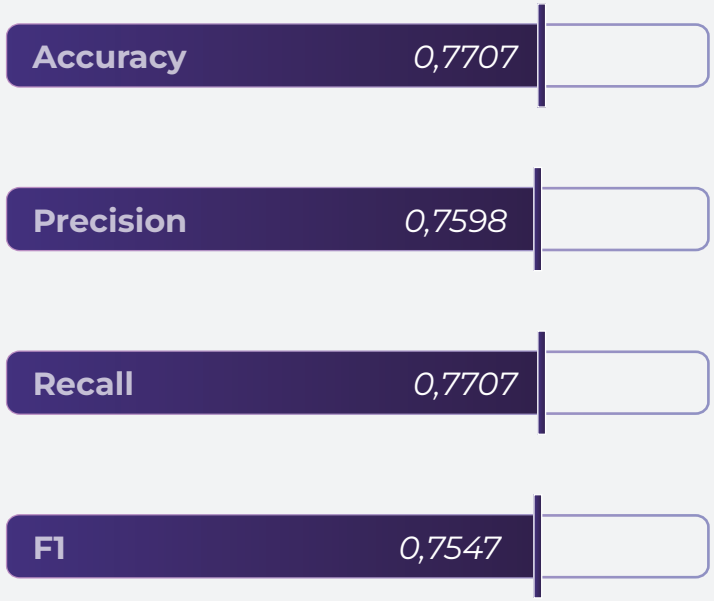

	precision	recall	f1-score	support
City	0.77	0.76	0.77	238
Creator	0.80	0.57	0.67	173
Duplo	0.86	0.97	0.91	392
Educational and Dacta	0.57	0.21	0.30	160
Friends	0.72	0.72	0.72	156
Ninjago	0.69	0.67	0.68	147
Star Wars	0.69	0.77	0.73	230
Technic	0.77	0.95	0.85	222
Town	0.83	0.89	0.86	185
Universal Building Set	0.75	0.85	0.80	117
accuracy			0.77	2020
macro avg	0.74	0.74	0.73	2020
weighted avg	0.76	0.77	0.75	2020

MATRIZ DE CONFUSIÓN | TRAIN DATA

MATRIZ DE CONFUSIÓN | TEST DATA

4.5. DECISION TREE BAGGING

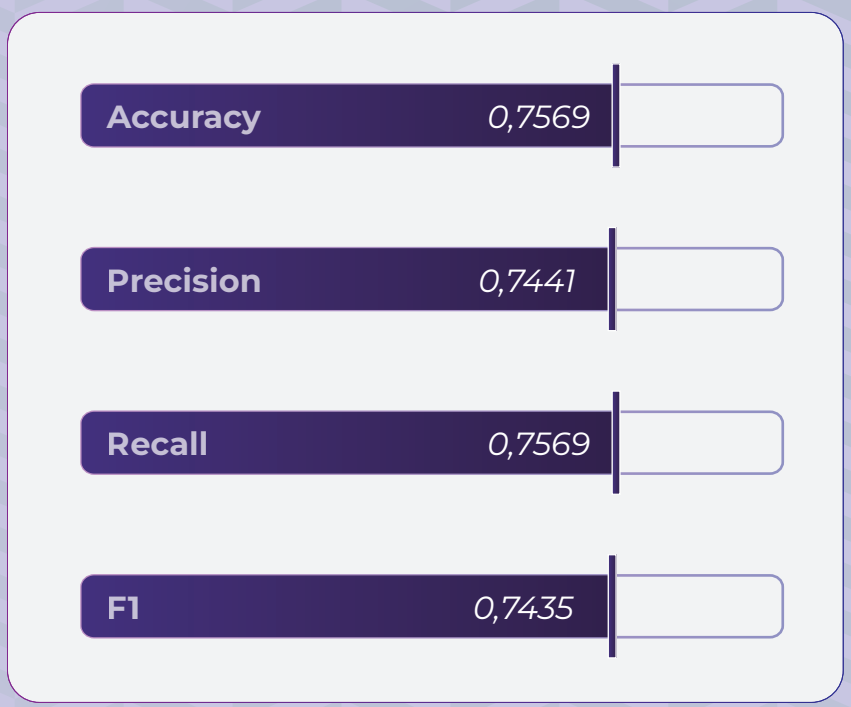

	precision	recall	f1-score	support
City	0.77	0.73	0.75	238
Creator	0.73	0.58	0.65	173
Duplo	0.87	0.97	0.92	392
Educational and Dacta	0.51	0.23	0.32	160
Friends	0.74	0.71	0.73	156
Ninjago	0.63	0.64	0.64	147
Star Wars	0.65	0.71	0.68	230
Technic	0.76	0.94	0.84	222
Town	0.82	0.89	0.85	185
Universal Building Set	0.80	0.81	0.81	117
accuracy			0.76	2020
macro avg	0.73	0.72	0.72	2020
weighted avg	0.74	0.76	0.74	2020

MATRIZ DE CONFUSIÓN | TRAIN DATA

MATRIZ DE CONFUSIÓN | TEST DATA

4.6. SUPPORT VECTOR MACHINE

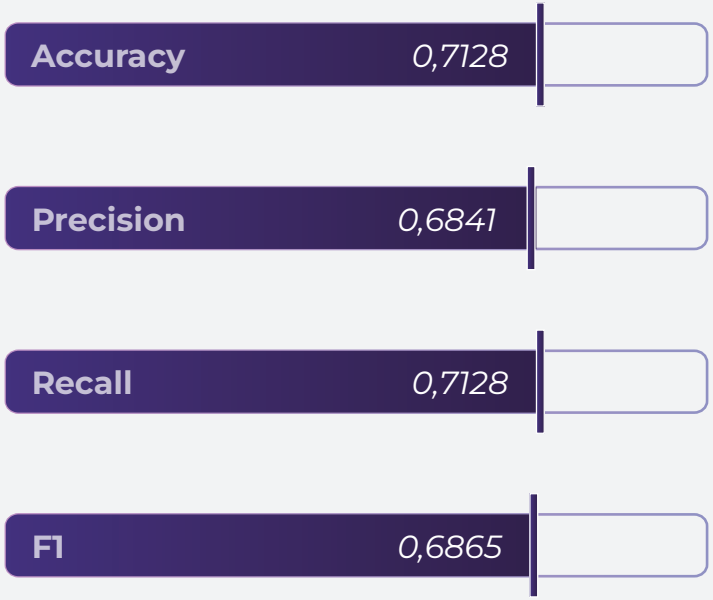

	precision	recall	f1-score	support
City	0.78	0.63	0.70	238
Creator	0.54	0.52	0.53	173
Duplo	0.85	1.00	0.92	392
Educational and Dacta	0.26	0.04	0.07	160
Friends	0.62	0.79	0.69	156
Ninjago	0.64	0.69	0.67	147
Star Wars	0.74	0.60	0.67	230
Technic	0.73	0.92	0.82	222
Town	0.73	0.76	0.74	185
Universal Building Set	0.59	0.79	0.68	117
accuracy			0.71	2020
macro avg	0.65	0.68	0.65	2020
weighted avg	0.68	0.71	0.69	2020

MATRIZ DE CONFUSIÓN | TRAIN DATA

MATRIZ DE CONFUSIÓN | TEST DATA

4.7. DECISION TREE CLASSIFIER

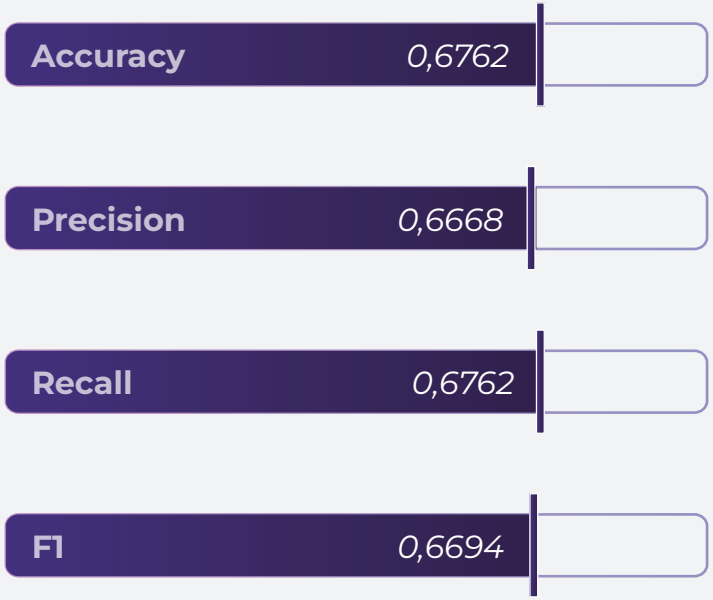

	precision	recall	f1-score	support
City	0.65	0.61	0.63	238
Creator	0.56	0.49	0.52	173
Duplo	0.87	0.89	0.88	392
Educational and Dacta	0.32	0.25	0.28	160
Friends	0.61	0.60	0.60	156
Ninjago	0.59	0.54	0.57	147
Star Wars	0.56	0.61	0.58	230
Technic	0.73	0.92	0.82	222
Town	0.78	0.82	0.80	185
Universal Building Set	0.75	0.68	0.71	117
accuracy			0.68	2020
macro avg	0.64	0.64	0.64	2020
weighted avg	0.67	0.68	0.67	2020

MATRIZ DE CONFUSIÓN | TRAIN DATA

MATRIZ DE CONFUSIÓN | TEST DATA

1. DATASET
2. EVALUACIÓN DE LOS MODELOS
3. SPLIT DATASET
4. MODELOS
5. **COMPARACIÓN DE LOS MODELOS**
6. AUTO ML
7. CONCLUSIONES

5.0. COMPARACIÓN DE MÉTRICAS ENTRE LOS MODELOS

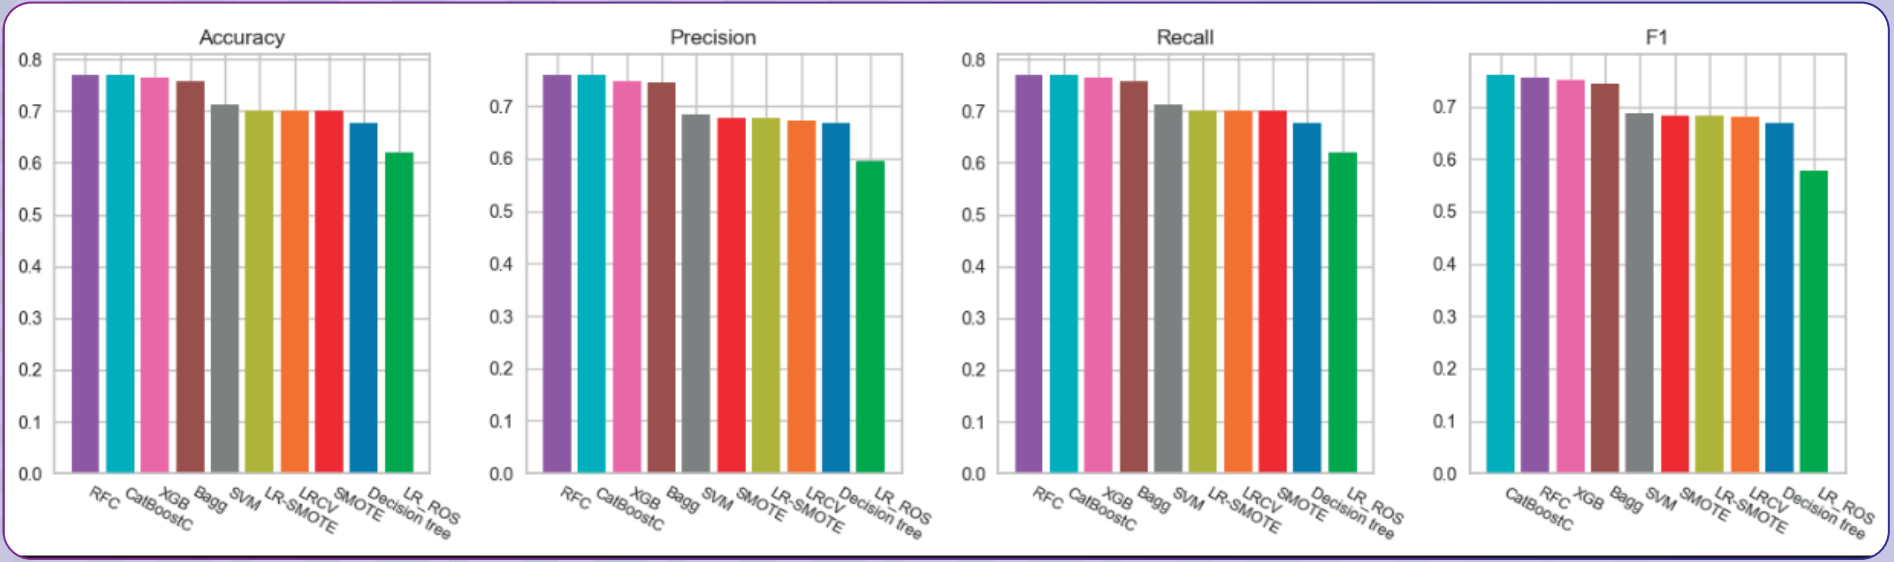

Aquí se comparan las métricas de Accuracy, Precision, Recall y F1 entre los diferentes modelos que se probaron, presentándose de forma descendente en función de su performance. Con esta forma de visualizar, se observa una buena performance entre los modelos Randon Forest Classifier y XGB classifier.

5.1.1. MÉTODO: LRCV BALANCED

COMPARACIÓN DE MÉTRICAS ENTRE CLASES

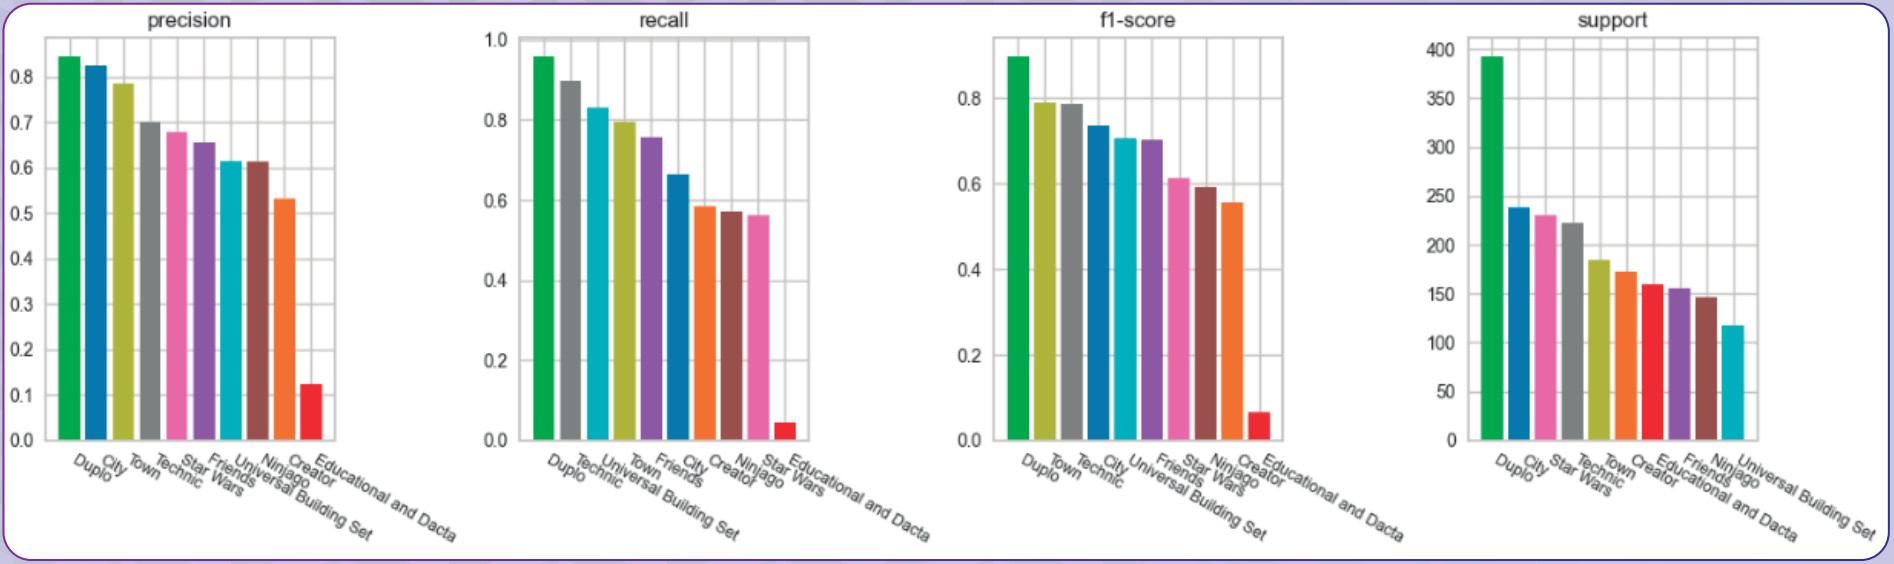

5.1.2. MÉTODO: LRCV WITH ROS

COMPARACIÓN DE MÉTRICAS ENTRE CLASES

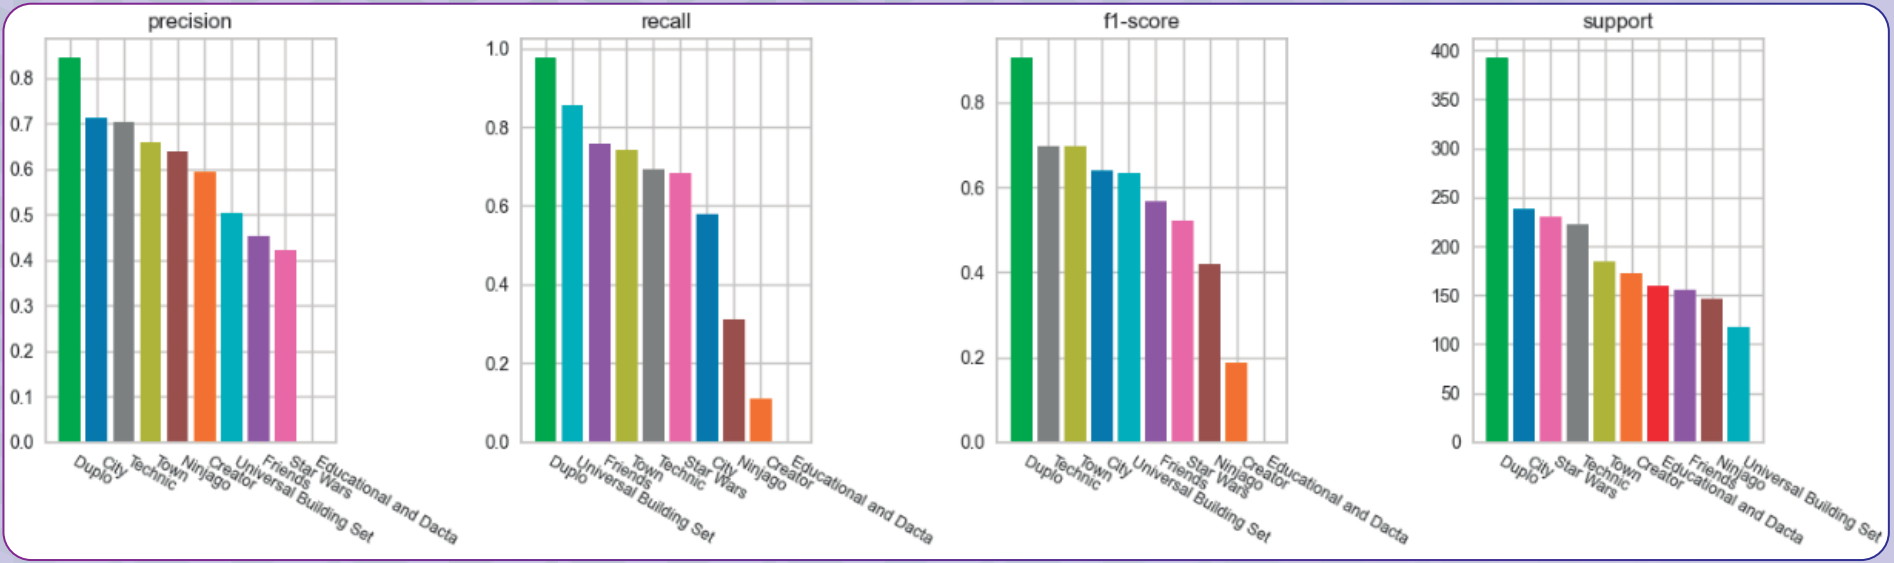

5.1.3. MÉTODO: LRCV WITH SMOTE
COMPARACIÓN DE MÉTRICAS ENTRE CLASES

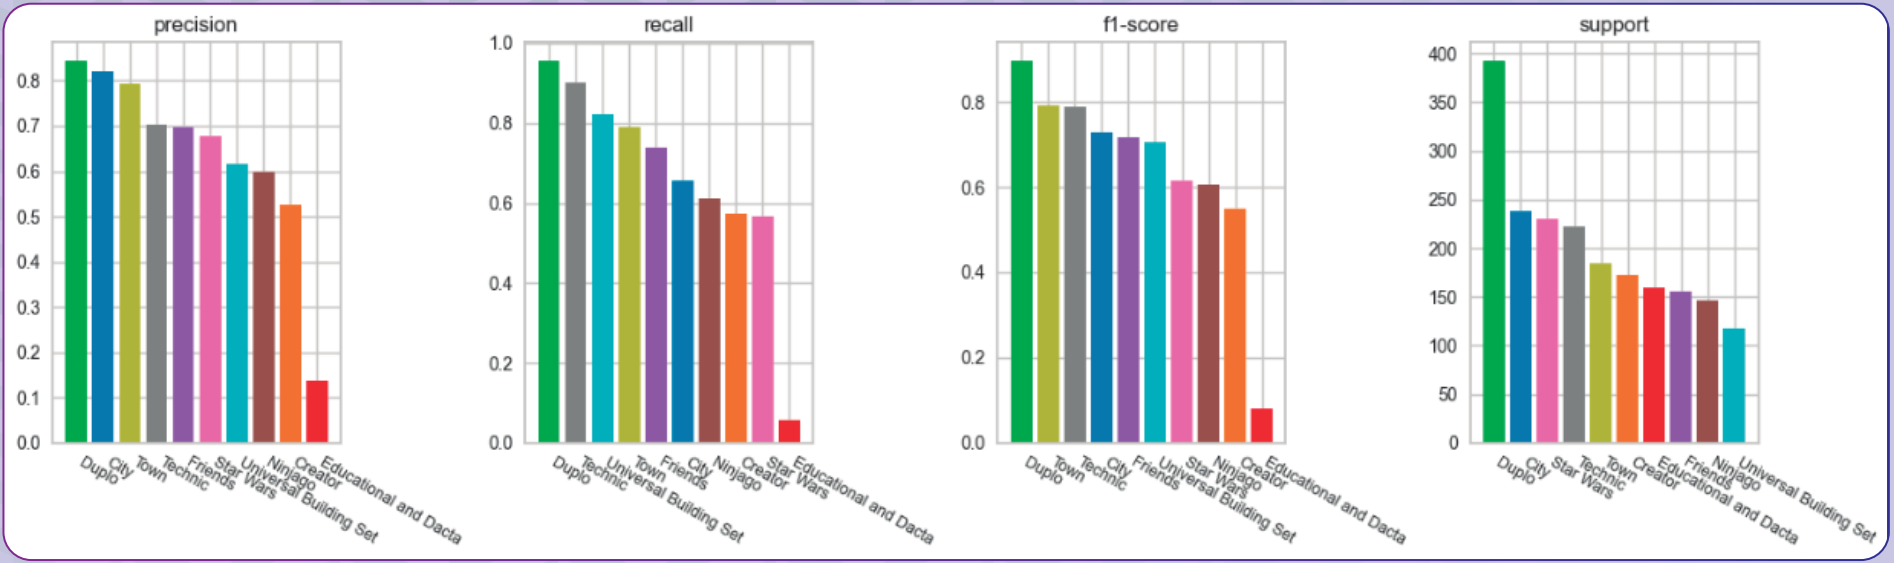

5.2. MÉTODO: XGB CLASSIFIER

COMPARACIÓN DE MÉTRICAS ENTRE CLASES

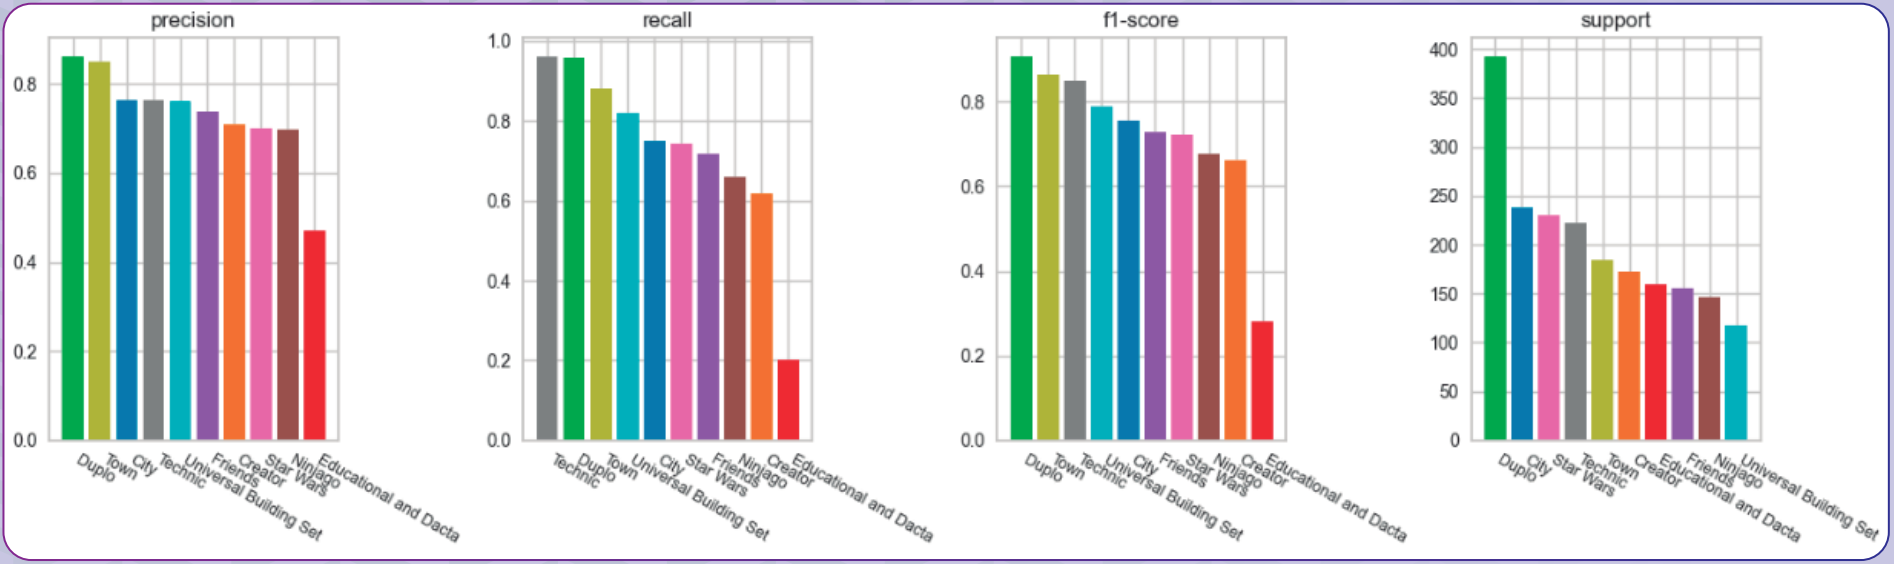

5.3. MÉTODO: CAT BOOST CLASSIFIER

COMPARACIÓN DE MÉTRICAS ENTRE CLASES

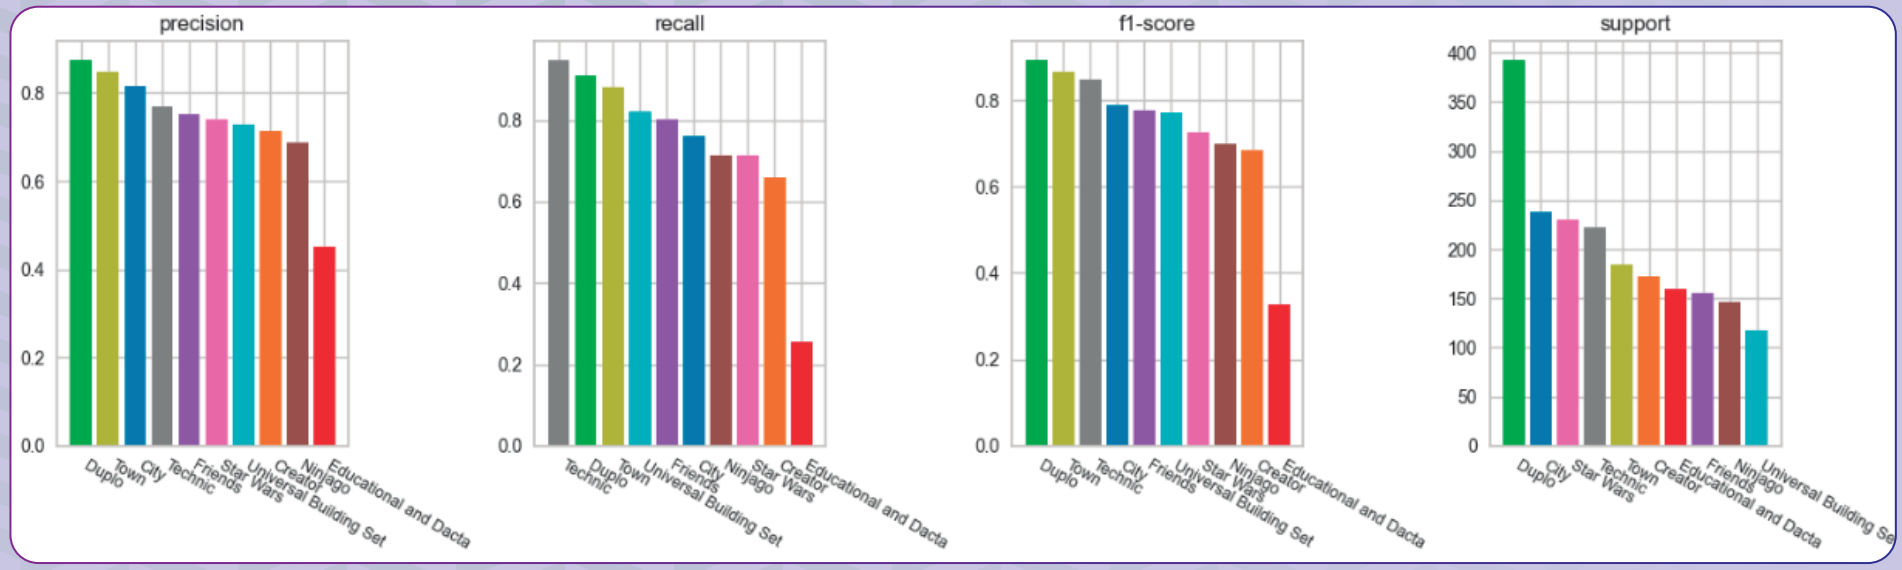

5.4. MÉTODO: RANDOM FOREST CLASSIFIER

COMPARACIÓN DE MÉTRICAS ENTRE CLASES

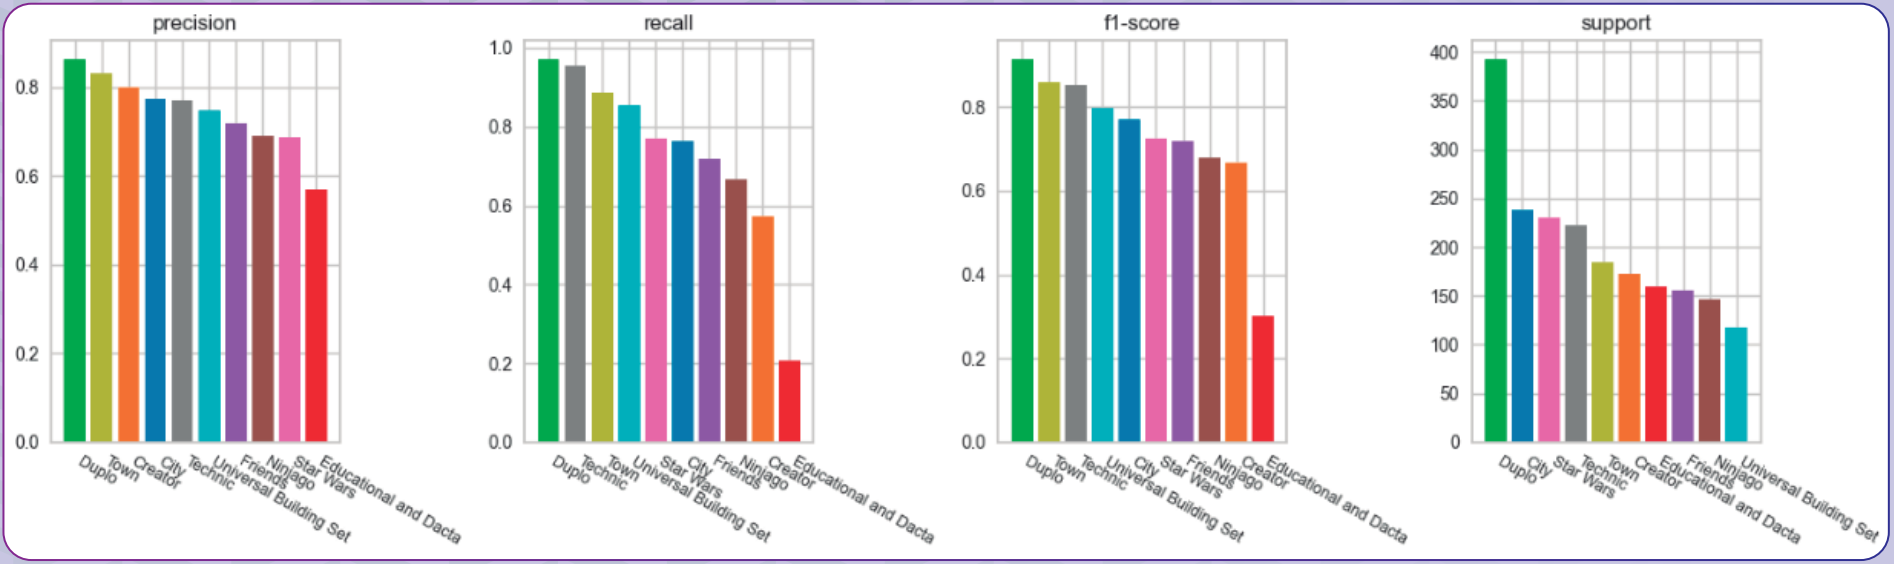

5.5. MÉTODO: BAGGING - TREE CLASSIFIER

COMPARACIÓN DE MÉTRICAS ENTRE CLASES

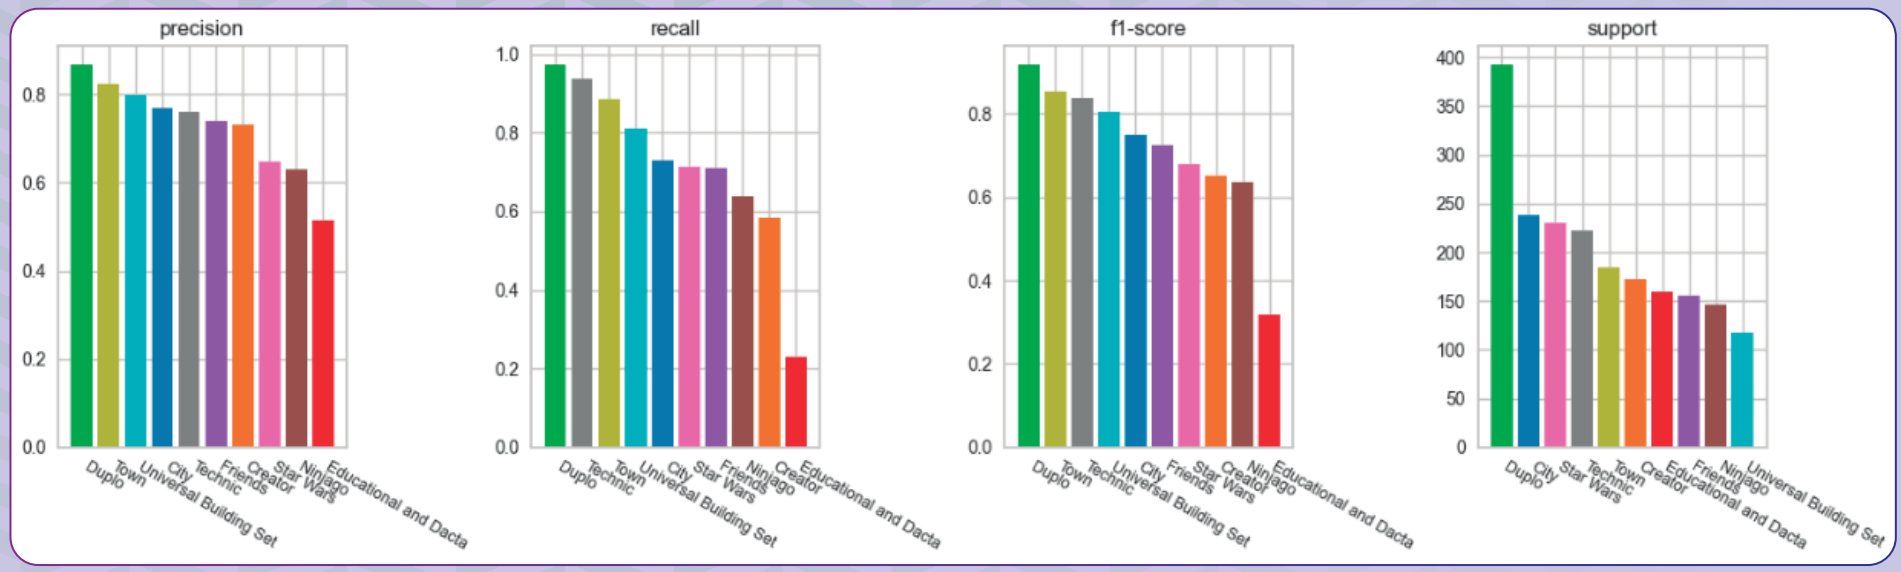

5.6. MÉTODO: SUPORT VECTOR MACHINE

COMPARACIÓN DE MÉTRICAS ENTRE CLASES

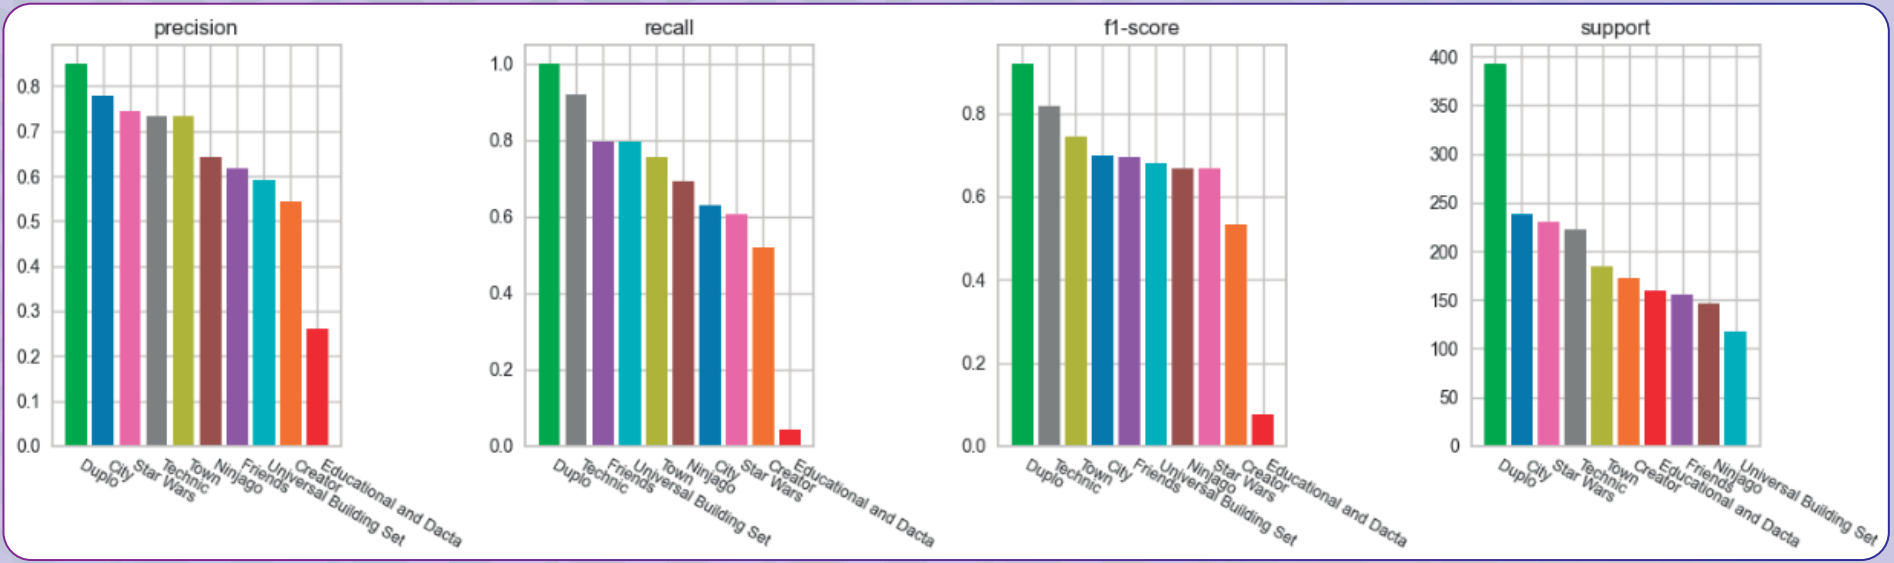

5.7. MÉTODO: DECISION TREE CLASSIFIER

COMPARACIÓN DE MÉTRICAS ENTRE CLASES

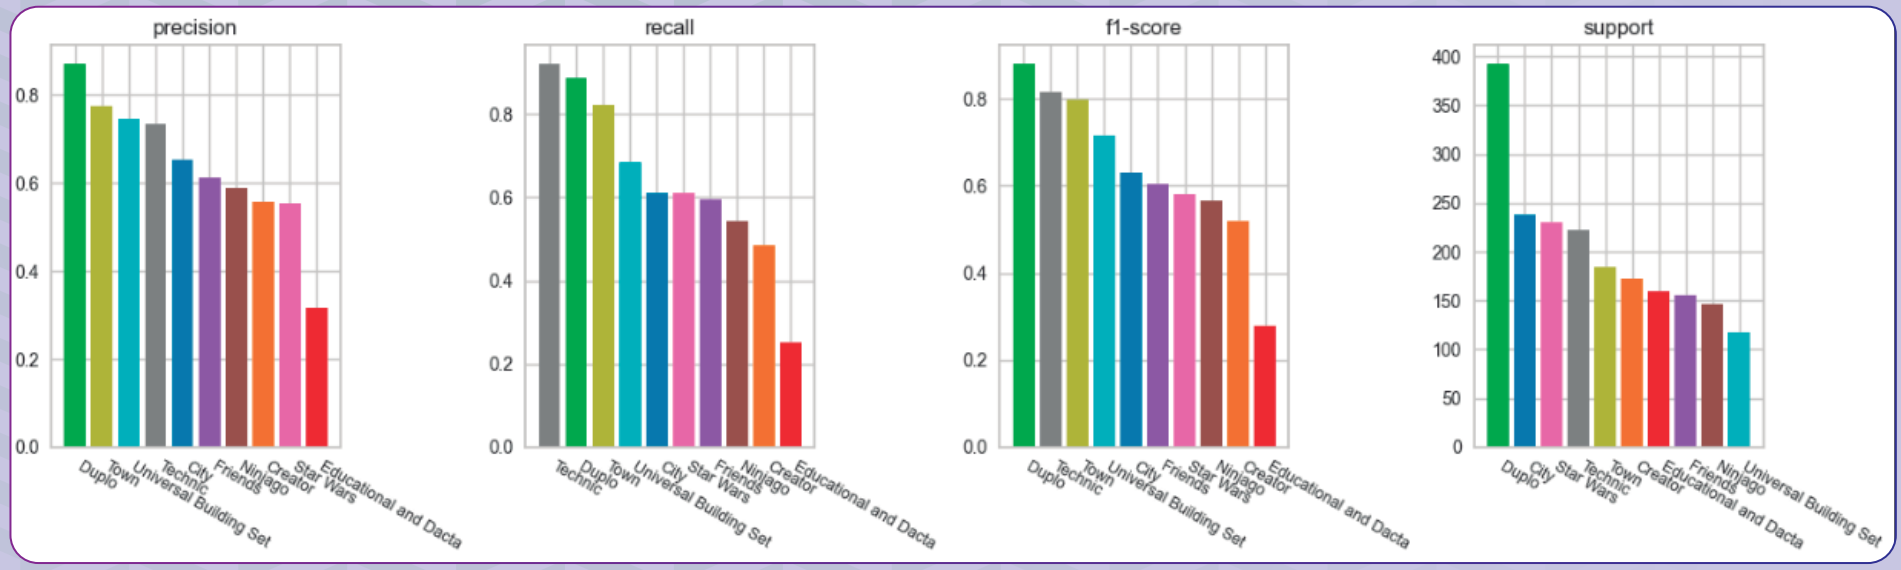

1. DATASET
2. EVALUACIÓN DE LOS MODELOS
3. SPLIT DATASET
4. MODELOS
5. COMPARACIÓN DE LOS MODELOS
6. AUTO ML
7. CONCLUSIONES

5.1. COMPARACIÓN DE MODELOS

	Model	Accuracy	AUC	Recall	Prec.	F1	Kappa	MCC
catboost	CatBoost Classifier	0.8784	0.9911	0.8784	0.8761	0.8742	0.8629	0.8636
lightgbm	Light Gradient Boosting Machine	0.8754	0.9881	0.8754	0.8737	0.8724	0.8596	0.8600
xgboost	Extreme Gradient Boosting	0.8741	0.9885	0.8741	0.8723	0.8706	0.8581	0.8587
rf	Random Forest Classifier	0.8510	0.9847	0.8510	0.8463	0.8423	0.8319	0.8331
et	Extra Trees Classifier	0.8497	0.9813	0.8497	0.8457	0.8408	0.8304	0.8317
gbc	Gradient Boosting Classifier	0.8495	0.9857	0.8495	0.8462	0.8445	0.8303	0.8311
lda	Linear Discriminant Analysis	0.7513	0.9460	0.7513	0.7356	0.7292	0.7192	0.7220
dt	Decision Tree Classifier	0.7494	0.8624	0.7494	0.7521	0.7490	0.7179	0.7183
ridge	Ridge Classifier	0.7209	0.0000	0.7209	0.7163	0.6834	0.6839	0.6898
lr	Logistic Regression	0.6787	0.9377	0.6787	0.6767	0.6553	0.6366	0.6420
nb	Naive Bayes	0.6776	0.9318	0.6776	0.6862	0.6487	0.6375	0.6460
qda	Quadratic Discriminant Analysis	0.6104	0.9042	0.6104	0.6468	0.5537	0.5623	0.5759
knn	K Neighbors Classifier	0.4003	0.7573	0.4003	0.4369	0.4014	0.3228	0.3280
ada	Ada Boost Classifier	0.2746	0.6976	0.2746	0.2304	0.2083	0.1704	0.2436
svm	SVM - Linear Kernel	0.2088	0.0000	0.2088	0.1519	0.1313	0.1040	0.1517
dummy	Dummy Classifier	0.1831	0.5000	0.1831	0.0335	0.0567	0.0000	0.0000

5.2. CREACIÓN DEL MODELO
CATBOOST CLASSIFIER

Fold	Accuracy	AUC	Recall	Prec.	F1	Kappa	MCC
0	0.8814	0.9922	0.8814	0.8781	0.8782	0.8663	0.8667
1	0.8983	0.9908	0.8983	0.8955	0.8941	0.8854	0.8860
2	0.8854	0.9919	0.8854	0.8846	0.8795	0.8706	0.8717
3	0.8556	0.9871	0.8556	0.8516	0.8476	0.8370	0.8383
4	0.8811	0.9912	0.8811	0.8818	0.8783	0.8661	0.8667
5	0.8747	0.9912	0.8747	0.8739	0.8715	0.8588	0.8594
6	0.8556	0.9925	0.8556	0.8527	0.8519	0.8374	0.8379
7	0.8832	0.9907	0.8832	0.8784	0.8789	0.8684	0.8689
8	0.8747	0.9922	0.8747	0.8729	0.8724	0.8588	0.8592
9	0.8938	0.9908	0.8938	0.8921	0.8890	0.8802	0.8810
Mean	0.8784	0.9911	0.8784	0.8761	0.8742	0.8629	0.8636
Std	0.0134	0.0015	0.0134	0.0138	0.0138	0.0151	0.0150

5.3. COMPARACIÓN DE MATRICES - TEST
CATBOOST | RANDOM FOREST

CATBOOST | AUTOML

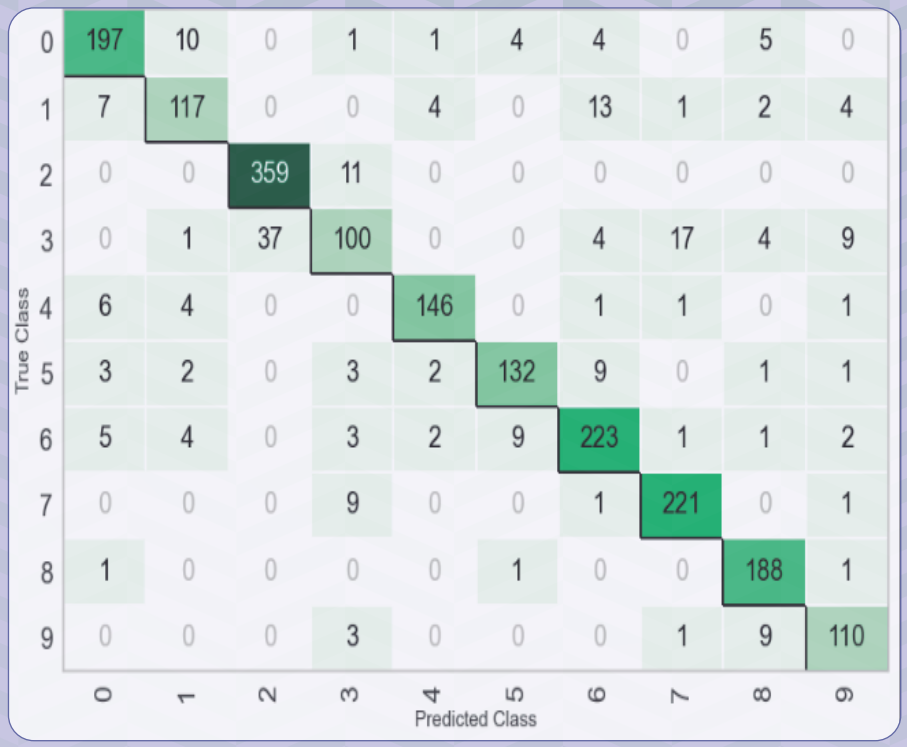

RANDOM FOREST | MANUAL

1. DATASET
2. EVALUACIÓN DE LOS MODELOS
3. SPLIT DATASET
4. MODELOS
5. COMPARACIÓN DE LOS MODELOS
6. AUTO ML
7. CONCLUSIONES

CONCLUSIONES

En el presente trabajo se utilizaron varios modelos de clasificación para intentar predecir a qué temática pertenece un set de Lego basado en su contenido. Antes de empezar con el entrenamiento de los modelos, se realizó un análisis exploratorio, se combinaron varios datasets y se preprocesaron los datos. Luego, se seleccionaron 12 features basado en top 20 por MÍ y luego eliminando features correlacionadas entre sí (Spearman). Luego, se entrenaron diferentes modelos de aprendizaje automático (Decision Tree, Random Forest, XGBoost, entre otros) utilizando técnicas de balanceo de clases y un split train-test de 70-30.

Se observa que los modelos con mejor performance en este caso son Random Forest (accuracy de 0.77, precision de 0.76, recall de 0.77, F1 de 0.75) y CatBoost (accuracy de 0.77, precision de 0.76, recall de 0.77, F1 de 0.76). Estos resultados indican que estos modelos tienen un desempeño aceptable en la clasificación de los sets de Lego en diferentes temáticas. Esto significa que es posible predecir con cierta precisión a qué temática pertenece un set de Lego analizando su contenido, en este caso, las proporciones de materiales, colores y categorías de las piezas.

CONCLUSIONES

La implementación de AutoML muestra que la mejor performance fue la del CatBoost (accuracy de 0.88, precision de 0.88, recall de 0.88, F1 de 0.87). Se puede concluir que hubo una mejora significativa en la performance en comparación con el modelo Random Forest Classifier previo, que tenía un accuracy de 0.77. Por un lado, utilizar AutoML nos permitió automatizar gran parte del proceso de selección y entrenamiento de modelos, lo que ahorra tiempo y recursos. Sin embargo, es importante considerar las limitaciones y desventajas asociadas, como son la pérdida de control y comprensión sobre el proceso.

¡muchas gracias!